

Inspirathèque

Pour vous aider à vous préparer au mieux – que vous soyez novice ou plus expérimenté – cette inspirathèque est créée pour vous.

Contraction des mots « inspiration » et « bibliothèque », l'inspirathèque est une bibliothèque d'inspiration. Elle vous permet de découvrir/redécouvrir des ressources qui pourront vous servir pour préparer vos outils de traitement de la donnée pour le week-end de prototypage qui vous attend.

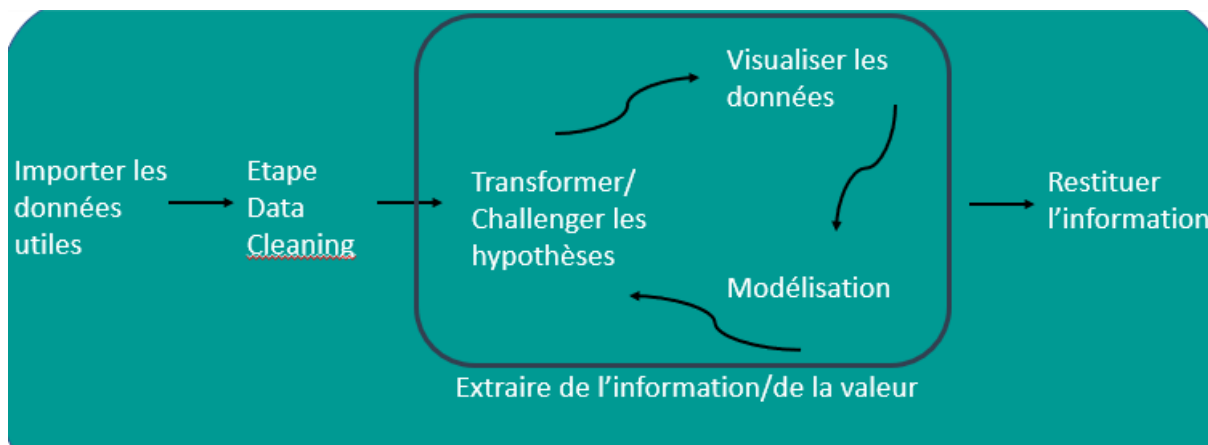
Les deux langages principalement présentés sont **R** et **Python**, néanmoins **cela n'empêche pas d'utiliser d'autres langages d'analyse lors du hackathon**.

Les rubriques sont alimentées au fur et à mesure, vous pouvez ainsi venir consulter régulièrement le site.

Les informations réunies ici proviennent de ressources de la communauté du libre. L'intégralité des liens vers les principaux contributeurs sont précisés dans la rubrique « crédits ».

Objectifs de cette rubrique :

- Vous permettre de comprendre les thématiques qu'il faut approfondir pour le cas d'usage que vous choisissez,
- Vous permettre de préparer au plus tôt vos outils pour le week-end intense de prototypage,
- Vous permettre d'orienter vos travaux vers des développements innovants (en ayant en tête un panorama des outils déjà existants évitant ainsi d'explorer des pistes déjà couvertes).



Source : R4DS – Hadley Wickham / Garrett Grolemund

Rubrique – Import de données

Langage R

- **Importer des fichiers plats avec le package `utils`**

Le package `utils` est chargé par défaut lorsque vous démarrez R.

Pour charger un fichier .txt avec un séparateur autre qu'un espace, la fonction `read.table()` est utile.

- **readr** → la fonction `read_csv()` de ce package permet également d'importer un fichier csv. La table en sortie sera aux formats `tbl_df`, `tibble` ou `dataframe` (`tble_df` et `tibble` étant des formats de tables R optimisés)
- **data.table** → ce package se distingue par la rapidité d'exécution – cette fonction gère automatiquement dans un fichier csv la présence d'entête de colonnes ou leur absence. Il reste toujours la possibilité de spécifier manuellement des options pour gérer le type des variables, le nom des colonnes etc. Il est également possible en utilisant cette fonction de sélectionner des variables par exemple. Les options de cette fonction sont nombreuses et valent la peine d'être investiguées.

Le package **Rvest** : permet d'extraire le contenu d'une page web à l'aide d'XPath ou de CSS.

Pandas : c'est une importante bibliothèque Python pour la manipulation des données, la requête et l'analyse. Elle fonctionne comme un ensemble intuitif et facile à utiliser pour effectuer des opérations sur n'importe quel type de données. Pour l'installer 'pip install pandas'.

Requests : téléchargement des fichiers et des pages Web à partir d'Internet.

La suite tidyverse : ensemble de packages pour manipuler vos données sous R – Cours Julien
Barnier : <https://juba.github.io/tidyverse/index.html>

Focus sur le package dplyr – un des packages du tidyverse
<http://www.rpubs.com/Marylene/test>

Le package data.table

Le package Stringr : package pour la gestion de caractères.

Quelques références utiles ressources R pour manipuler vos données :

Dplyr, Introduction : <https://cran.rstudio.com/web/packages/dplyr/vignettes/introduction.html>

Dplyr, manipulation de deux tables : <https://cran.r-project.org/web/packages/dplyr/vignettes/two-table.html>

Tidyr : <https://cran.r-project.org/web/packages/tidyr/tidyr.pdf>

Aide mémoire de Rstudio sur dplyr et tidyr : <https://www.rstudio.com/wp-content/uploads/2016/01/data-wrangling-french.pdf>

Si vous préférez vous mettre à data.table

<https://s3.amazonaws.com/assets.datacamp.com/img/blog/data+table+cheat+sheet.pdf>

Langage Python

Rubrique – Visualiser ses données (datavisualisation)

Je n'ai aucune compétence en programmation ou en graphisme, y-a-t-il des outils de datavisualisation qui peuvent me servir ?

Le site **datawrapper** <https://academy.datawrapper.de/> permet à la fois de vous initier aux principes et aux concepts de la datavisualisation mais également de réaliser des visualisations de données. De nombreux tutoriels courts de prise en main existent.

Les logiciels de datavisualisation

- Tableau
- Qlick
- PowerBi

Langage R : visualiser vos données

Package ggplot2 : initiation à l'utilisation du packages – principaux éléments http://r-toulouse.netlify.com/diapos/2018-09-25_ggplot2_initiation.pdf

Package esquisse de DreamRs : pour réaliser des graphiques ggplot2 de manière interactive

Package shiny (et son écosystème de packages associés). Pour maîtriser les bases de Shiny (langage R) : <https://mastering-shiny.org/preface> par Hadley Wickham

Package Golem ThinkR – un outil pour la construction d'applications Shiny pour la production : <https://rtask.thinkr.fr/fr/demarrer-avec-golem/>

Langage Python : visualiser vos données

Matplotlib : cette bibliothèque permet de faire de la visualisation.

Des « helpers » pour personnaliser vos graphiques R ou Python

Choix d'une couleur : <https://flatuicolors.com/>

Les thématiques importantes en lien avec les cas d'usage de l'idéathon

Infogram : pour créer des graphiques, des cartes et des infographies

Visme : pour créer des graphes et des infographies

- **UX/UI design**

Pour une liste d'outils UX : uxtools.co

Pour prototypes web et mobile : InVision (permet de hiérarchiser des projets / écrans de manière simple et claire.)

- **Séries temporelles / analyses de données / méthodes supervisées / méthodes non supervisées /deep learning**

Rubrique - Ressources pour approfondissement

Traitement des données

Livre interactif gratuit « R for DataScience – Hadley Wickham, Garrett Golemund » : <https://r4ds.had.co.nz/index.html>

Ce livre permet d'apprendre à traiter des données sous R, les importer, les mettre en forme, les visualiser, les modéliser et les restituer.

Accéder aux API de l'Etat

Le site www.api.gouv.fr permet un accès unique aux API de l'Etat. N'hésitez pas à y jeter un œil. Certaines API sont en accès direct et totalement libre, d'autres nécessitent une mise à disposition en contactant leur propriétaire. Si vous êtes d'ores et déjà intéressé par un cas d'usage, vous pouvez contacter le support de certaines API afin d'obtenir l'accès aux outils qui vous intéressent.

Travailler en mode projet sous RStudio

Organiser son projet : <https://nicercode.github.io/blog/2013-04-05-projects/>

Autres ressources

Etalab lance <https://code.etalab.gouv.fr/>, les données sous-jacentes permettent de filtrer sur le langage principal de chaque dépôt : <https://www.data.gouv.fr/fr/datasets/inventaire-des-depots-de-code-source-des-organismes-publics/>

Par exemple, on trouve 27 projets R produits par l'administration, pour la communauté #rstats française. <https://pbs.twimg.com/media/EGbSNTEXkAIMzJq.png>

Compléter les données / trouver des données complémentaires pour traiter le cas d'usage que vous choisissez

Rubrique : quels développements/travaux déjà effectués pouvant vous inspirer ?

https://www.collectivites-locales.gouv.fr/files/files/statistiques/bis_138_contractuels_fpt_bs2017_1.pdf

Des travaux conduits en 2017 / 2018 par la Caisse des dépôts, en lien avec les employeurs publics, sur l'usure professionnelle et le maintien dans l'emploi, qui ont donné lieu à un « référentiel » à l'usage des employeurs. (À lire pour vous informer de ces questions RH très spécifiques).

<https://www.cnracl.retraites.fr/employeur/actualites/recueil-du-maintien-dans-lemploi-des-fonctionnaires-territoriaux-et-hospitaliers>